

# AVANCE 3


ENTENDIMIENTO Y PREPARACIÓN DE LA DATA

# CLASES DEL DATASET

# DATASET

SKIN CANCER MNIST: HAM10000

Colección de imágenes dermatoscópicas de lesiones pigmentadas de múltiples fuentes.



10 015 imágenes



6 GB



7 tipos de lesiones de piel

- Queratosis actínica/carcinoma intraepitelial (AKIEC)
- Carcinoma basocelular (BCC)
- Queratosis benigna (BKL)
- Dermatofibroma (DF)



AKIEC




BCC



BKL



DF



MEL






NV



VASC





- Melanoma (MEL)
- Nevus melanocíticos (NV)
- Lesiones vasculares (VASC)

# QUERATOSIS ACTÍNICA/CARCINOMA INTRAEPITELIAL (AKIEC)



- La queratosis actínica es una lesión cutánea **precancerosa** que se desarrolla a partir de una exposición crónica a los **rayos ultravioleta**. [3]
- Se presenta como manchas **ásperas** y **escamosas** en la piel, especialmente en áreas expuestas al sol, como la cara, el cuello y las manos. [3]
- Si no se trata, puede progresar a carcinoma de células escamosas, un tipo de cáncer de piel más invasivo.



# CARCINOMA BASOCELULAR (BCC)



- Es el tipo más **común** de cáncer de piel. [2]
- Surge en las células basales de la epidermis, típicamente debido a la exposición prolongada a la **radiación ultravioleta**.
- Se manifiesta como **nódulos perlados**, **úlceras** o **placas rosadas** en la piel.
- Puede causar daño significativo si no se trata, ya que tiende a invadir localmente los tejidos circundantes.






# QUERATOSIS BENIGNA (BKL)







- Es un crecimiento **no canceroso** que aparece en la piel de personas mayores. [2]
- Se caracteriza por **manchas marrones**, negras o de color carne que son cerosas, elevadas y a menudo parecen estar "**pegadas**" a la piel. [2]

# DERMATOFIBROMA (DF)



- Generalmente se presenta como un **nódulo firme**, de color marrón o rojizo, que puede variar en **tamaño**.
- Aunque los dermatofibromas son **inofensivos**, pueden causar molestias o picazón y, ocasionalmente, son removidos por razones estéticas o debido a irritación persistente.




# MELANOMA (MEL)



- Es un tipo **agresivo** de cáncer de piel que se origina en los **melanocitos**, las células productoras de pigmento. [2][3]
- Los melanomas a menudo se presentan como **manchas** o **lunares** nuevos que son **asimétricos**, de **bordes irregulares**, con **múltiples colores** y que cambian de tamaño o forma con el tiempo. [3]
- Tiene la capacidad de hacer **metástasis** a otros órganos [2][3]






# NEVUS MELANOCÍTICOS (NV)



- Comúnmente conocidos como **lunares**, son proliferaciones **benignas** de **melanocitos**. [2]
- Suelen ser de color **marrón** o **negro**, y pueden ser **planos** o **elevados**.
- Aunque la mayoría son **inofensivos**, algunos pueden transformarse en melanoma. [2]

# LESIONES VASCULARES (VASC)




- Anormalidades de los **vasos sanguíneos** en la piel que pueden ser congénitas o adquiridas.
- Incluyen una variedad de afecciones, como **hemangiomas**, **malformaciones vasculares** y **manchas de vino de Oporto**.
- Estas lesiones pueden variar en apariencia desde **manchas rojas planas** hasta **masas elevadas de color púrpura**.

# METADATOS

	lesion_id	image_id	dx	dx_type	age	sex	localization
0	HAM_0000118	ISIC_0027419	bkl	histo	80.0	male	scalp
1	HAM_0000118	ISIC_0025030	bkl	histo	80.0	male	scalp
2	HAM_0002730	ISIC_0026769	bkl	histo	80.0	male	scalp
3	HAM_0002730	ISIC_0025661	bkl	histo	80.0	male	scalp
4	HAM_0001466	ISIC_0031633	bkl	histo	75.0	male	ear


- lesion\_id: Identificador único de la lesión
- image\_id: Identificador único de la imagen
- dx: Diagnóstico de la lesión (tipo de lesión)
- dx\_type: Tipo de diagnóstico
- age: Edad del paciente
- sex: Sexo del paciente (femenino o masculino)
- localization: Ubicación de la lesión en el cuerpo

## Distribución de diagnósticos



- Variedad de diagnóstico
- Desbalance de clases


## Distribución de localizaciones



- Variabilidad en la localización
- Localizaciones predominantes y menos comunes




## Distribución de edad



- Mayor concentración de pacientes en los rangos de edad de adultos mayores
- Presencia de jóvenes

## Distribución de sexo




- Desigualdad de clases


# **DATASET**

# DISTRIBUCIÓN

- Cantidad de datos totales: 10 015
- Cantidad de datos de entrenamiento (81.69%): 8181
- Cantidad de datos de test (8.27%): 828
- Cantidad de datos de validación (10.04%): 1006




Distribución de diagnósticos



Distribución de lesiones del dataset



# DATA AUGMENTATION

- Se implementó una técnica de data augmentation utilizando **ImageDataGenerator** de TensorFlow.
- Las imágenes se sometieron a varias **transformaciones aleatorias**, como rotaciones de hasta 180 grados, desplazamientos horizontales y verticales de hasta un 10% del tamaño de la imagen, zooms aleatorios, y volteos horizontales y verticales.
- Las imágenes transformadas se guardaron con un tamaño de **299x299** píxeles en formato JPG.
- Se generó un total de **8000** imágenes aumentadas por clase





# DESCOMPOSICIÓN



- La imagen original del conjunto de datos se descompone en los canales **R**, **G** y **B** antes del entrenamiento.
- Se obtienen tres matrices **U** (valor singular izquierdo) , **S** (valor singular) y **V** (valor singular derecho) tras la descomposición del valor singular (SVD). Se utilizó  $k = 90$ .

$$A_{(m,n)} = U_{(m,k)} \cdot \Sigma_k \cdot V_{(k,n)}$$

# MÉTRICAS

# ACCURACY

Es la proporción de las clasificaciones correctas entre el número total de casos. En este caso, mide qué tan bien FixCaps clasifica correctamente las lesiones cutáneas entre todas las imágenes evaluadas.

Se comparo el rendimiento de FixCaps otros modelos de red neuronal al clasificar lesiones cutáneas, como se muestra en la Tabla 1.

- FixCaps supera a GoogLeNet, IRv2 y otros métodos en términos de accuracy en el conjunto de datos HAM10000.
- FixCaps tiene menos parámetros y una menor complejidad que IRv2-SA.
- FixCaps tiene 6.74 mil millones de FLOPs, lo cual representa solo el 26% de los FLOPs de IRv2-SA (25.46 mil millones de FLOPs).
- FixCaps-DS tiene 0.14 millones de parámetros, lo que equivale aproximadamente al 10% de los parámetros de MobileNet V3 (1.53 millones de parámetros).

$$Accuracy = \frac{TP + TN}{T}$$

TN - Verdadero Negativo

TP - Verdadero Positivo

FP - Falso Positivo


FN - Falso Negativo

T - Número total de muestras

Method	Accuracy[%]	Params(M)	FLOPs(G)
GoogLeNet	83.94	5.98	1.58
Inception V3	86.82	22.8	5.73
MobileNet V3	89.97	1.53	0.12
IRv2-SA	93.47	47.5	25.46
<b>FixCaps-DS</b>	<b>96.13</b>	0.14	0.08
<b>FixCaps</b>	<b>96.49</b>	0.50	6.74

**Tabla 1.** Exactitud de clasificación (%) en el conjunto de prueba HAM10000.

FixCaps-DS tiene 0.08 mil millones de FLOPs, lo que representa solo el 66% de MobileNet V3 (0.12 mil millones de FLOPs). [1]



**Figura 5.** La exactitud se evalúa en el conjunto de prueba utilizando diferentes LKC. El término "kernel-N" denota un kernel de convolución de  $N \times N$  en FixCaps. [1]

Como se muestra en la Figura 5, el rendimiento de FixCaps en el conjunto de prueba fue evaluado utilizando diferentes LKC. Finalmente, se encontró que la convolución con un tamaño de kernel de  $31 \times 31$  mostró el mejor rendimiento.

Este trabajo ha demostrado la efectividad de FixCaps en la predicción de clases de imágenes dermatoscópicas, y ha demostrado que el uso de kernels de convolución grandes en lugar de una pila de pequeños kernels podría ser un paradigma más poderoso.



# F1-SCORE

- Es la media armónica entre precisión y recall.
- Proporciona un balance entre la capacidad del modelo de detectar casos positivos y evitar falsos positivos.
- Es útil cuando se busca un equilibrio entre precisión y exhaustividad, especialmente en conjuntos de datos no balanceados.

F1-score y el área bajo la curva AUC buscan que se puedan detectar las muestras verdaderamente positivas. La diferencia es que el AUC apunta a un modelo con la menor cantidad de falsos positivos posible, mientras que el F1-score se enfoca en un modelo que no omita ninguna posibilidad. Se espera diagnosticar la mayor cantidad de casos sospechosos posible, por lo que preferimos el F1-score como el índice de evaluación del modelo.

$$F_1 - score = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

Dis.	F <sub>1</sub> -score								
	9	11	13	15	18	21	27	31	35
AKIEC	0.323	0.488	0.545	0.634	0.818	0.880	0.809	<b>0.917</b>	0.800
BCC	0.410	0.557	0.767	0.738	0.774	0.815	0.772	<b>0.898</b>	0.772
BKL	0.426	0.516	0.811	0.806	0.824	0.832	0.770	<b>0.881</b>	0.739
DF	0	0	0.444	0.333	0.400	0.545	0.533	0.615	<b>0.625</b>
MEL	0.261	0.246	0.853	0.600	0.774	0.829	0.722	<b>0.925</b>	0.687
NV	0.923	0.929	<b>0.989</b>	0.975	0.989	0.980	0.972	0.985	0.966
VASC	0.588	0.667	<b>0.947</b>	0.778	0.842	0.889	0.737	0.824	0.889

**Tabla 3.** El F1-score es evaluado en el conjunto de prueba utilizando diferentes LKC.

# PRECISION

- Indica qué tan preciso es el modelo cuando predice un caso positivo.
- Un valor alto de precisión significa que cuando el modelo identifica algo como positivo, es muy probable que sea correcto.
- Es especialmente útil cuando el costo de los falsos positivos es alto.

$$Precision = \frac{TP}{TP + FP}$$

TN - Verdadero Negativo

TP - Verdadero Positivo

FP - Falso Positivo

FN - Falso Negativo

T - Número total de muestras

# RECALL

- Mide la proporción de casos positivos reales que fueron identificados correctamente
- Es especialmente importante en aplicaciones médicas, ya que indica qué tan bien el modelo detecta los casos de enfermedad.
- Un alto recall significa que se están detectando la mayoría de los casos positivos.

$$\text{Recall} = \frac{TP}{TP + FN}$$

TN - Verdadero Negativo

TP - Verdadero Positivo

FP - Falso Positivo

FN - Falso Negativo

T - Número total de muestras

# **ARQUITECTURA DEL MODELO**



```

-----
Layer (type)              Output Shape              Param #
=====
Conv2d-1                   [-1, 3, 141, 141]        975
Conv2d-2                   [-1, 128, 71, 71]        512
BatchNorm2d-3              [-1, 128, 71, 71]        256
ReLU-4                     [-1, 128, 71, 71]        0
FractionalMaxPool2d-5      [-1, 128, 20, 20]        0
Conv2d-6                   [-1, 128, 20, 20]        16,384
BatchNorm2d-7              [-1, 128, 20, 20]        256
Hardswish-8                [-1, 128, 20, 20]        0
AdaptiveAvgPool2d-9        [-1, 128, 1, 1]         0
Conv2d-10                  [-1, 128, 1, 1]         16,384
ReLU-11                    [-1, 128, 1, 1]         0
Conv2d-12                  [-1, 128, 1, 1]         16,384
AdaptiveMaxPool2d-13       [-1, 128, 1, 1]         0
Conv2d-14                  [-1, 128, 1, 1]         16,384
ReLU-15                    [-1, 128, 1, 1]         0
Conv2d-16                  [-1, 128, 1, 1]         16,384
Sigmoid-17                 [-1, 128, 1, 1]         0
ChannelAttention-18         [-1, 128, 1, 1]         0
Conv2d-19                  [-1, 1, 20, 20]         18
Sigmoid-20                 [-1, 1, 20, 20]         0
SpatialAttention-21         [-1, 1, 20, 20]         0
Conv_CBAM-22               [-1, 128, 20, 20]        0
...
Forward/backward pass size (MB): 17.30
Params size (MB): 0.64
Estimated Total Size (MB): 18.96

```

```

for epoch in range(1, num_epochs + 1):
    train(epoch)
    test('val')

print('Finished Training')

```

🔄 15m 59.6s

[Train Epoch:1]images ==> Training ...

50%|██████ | 207/414 [15:03<28:41, 8.32s/it]

[207/414] Loss0.00000,ACC:1.00000

54%|██████ | 224/414 [15:59<17:09, 5.42s/it]

# REFERENCIAS

- [1] Z. Lan, S. Cai, X. He and X. Wen, "FixCaps: An Improved Capsules Network for Diagnosis of Skin Cancer," in IEEE Access, vol. 10, pp. 76261–76267, 2022, doi: 10.1109/ACCESS.2022.3181225. keywords: {Convolution;Skin;Lesions;Kernel;Deep learning;Medical diagnostic imaging;Mathematical models;Capsule network;CBAM;image classification;large–kernel convolution;skin cancer},
- [2] Urso C. Melanocytic Skin Tumors: Genetic Aberrations and Clinicopathological Classification. Dermatol Pract Concept. 2019 Dec 31;10(1):e2020005. doi: 10.5826/dpc.1001a05. PMID: 31921492; PMCID: PMC6936634.
- [3] Bastian BC, de la Fouchardiere A, Elder DE, et al. Genomic landscape of melanoma. In: Elder DE, Massi D, Scolyer RA, Willemze R, editors. WHO Classification of Skin Tumours. 4th ed. Lyon, France: IARC; 2018. pp. 72–75. [[Google Scholar](#)]



POR TU ATENCIÓN

GRACIAS

